

Segmentacja nerek i ich zmian nowotworowych na zdjęciach uzyskanych techniką tomografii komputerowej.

1. Cel projektu

Celem projektu było zaproponowanie oraz zaimplementowanie metody segmentacji nerek i ich nowotworów z zdjęć tomografii komputerowej. Należało również przedstawić metodę oceny uzyskanych wyników.


2. Preprocessing

W celu otwarcia biblioteki zawierającej zdjęcia nerek wykorzystano przypisaną bibliotekę `starter.utils`. Dzięki niej wyznaczono maski oraz zdjęcia. Na tym etapie zmniejszono wielkość zdjęć w celu zwiększenia szybkości wykonywanych obliczeń do rozmiaru 128x128.

3. Metody

3.1. Wykorzystane metody do segmentacji

Do segmentacji obrazów wykorzystano konwolucyjne sieci neuronowe U-Net. Została ona przedstawiona na grafice poniżej.



Rysunek 1. Architektura sieci U-Net.

Jest ona rodzaju decoder-encoder, co widać po jej charakterystycznym wyglądzie. Jest to typowa architektura dla konwolucyjnych sieci neuronowych. Posiada powtarzające się 2

konwolucyjne warstwy 3x3 z funkcją aktywacji ReLU oraz funkcją odcięcia o wartości 0,5. W każdym kroku zmniejszania rozmiaru analizowanego obrazu podwajane są ilości ekstrahowanych cech. Proces ten polega na wyekstrahowaniu cech potrzebnych do semantycznej segmentacji obrazów. Następnie w procesie encoder'a wykonywane są konwolucje "do góry", co powoduje zwiększenie rozmiaru obrazu oraz zmniejszenie ilości ekstrahowanych cech. Każda warstwa jest łączona z równą sobie z procesu decoder'a. Na wyjściu otrzymuje się maskę określającą wyznaczone cechy.

3.2. Wykorzystane metody do ewaluacji

Do oceny segmentacji wykorzystano współczynnik Jaccarda, który używany jest do porównywania zbiorów. Wskaźnik ten opiera się na nakładaniu masek powstałych w wyniku zaprezentowanego algorytmu segmentacji oraz poprawnej segmentacji. Zdefiniowany jest w następujący sposób:

$$JAC = \frac{|S \cap T|}{|S \cup T|}$$

Gdzie S oznacza segmentację wyznaczoną przez przedstawiony algorytm, a T to segmentacja poprawna.

Wartość wskaźnika mieści się w przedziale 0-1, gdzie wartość 0 oznacza brak nakładania się masek co równoznaczne jest z słabą jakością algorytmu, a wartość 1 oznacza idealnie nakładającą się segmentację.

Współczynnik przeliczono dla każdej warstwy obrazu zarówno dla nerki jak i nowotworu. Do oceny poprawności algorytmu wyznaczono średnią współczynników Jaccarda dla wszystkich testowanych obrazów.

4. Wyniki

W procesie trenowania uzyskiwano wynik na poziomie 0,98, jednakże dość duża wartość dla funkcji straty o wartości około 0,28.

5. Podsumowanie i wnioski

Segmentacja nerki jest bardzo trudnym zadaniem do wykonania klasycznymi technikami przetwarzania obrazów medycznych. Jednakże ciągle rozwijająca się nauka deep learning, dzięki przeprowadzanej ogromnej ilości obliczeń matematycznych pozwala wykonać takie zadanie.

6. Bibliografia.

[1] "Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool" - Abdel Aziz Taha and Allan Hanbury

[2] “Automated 3-D lung tumor detection and classification by an active contour model and CNN classifier” - Gopi Selvakumar, Jayakumar Amir, H.Gandomi, Manikandan Ramachandran, Simon Jame Fong, Rizwan Patan.

[3] “MSS U-Net: 3D segmentation of kidneys and tumors from CT images with a multiscale supervised U-Net” - Wenshuai Zhao, Dihong Jiang, Jorge Peña Queraltá, Tomi Westerlund

[4] “Segmentation of deformed kidneys and nephroblastoma using Case-Based Reasoning and Convolutional Neural Network” - Florent Mariea, Lisa Corbat, Yann Chaussy, Thibault Delavellea, Julien Henriet, Jean-Christophe Lapayrea

[5] “Using multi-layer perceptron with Laplacian edge detector for bladder cancer diagnosis” - Ivan Lorencina, Nikola Anđelića, Josip Španjolb, Zlatan Cara

Podział zadań

Wszystkie kroki planujemy wykonywać w pełnej współpracy ze sobą, aby każdy z członków zespołu mógł zapoznać się z poszczególnymi etapami pracy.